

Retrieval-Augmented Generation (RAG)

CHEAT SHEET #02

Cheat Sheet & Pipeline Fundamental — SECOMP 2026

📌 O que é RAG?

O **RAG** combina a capacidade de geração de texto dos LLMs com a busca de informações em bases de conhecimento próprias, garantindo respostas fundamentadas e sem alucinações.

🔧 O Pipeline Clássico de 5 Etapas

1. **Ingestão de Documentos:** Leitura e extração de texto de PDFs, JSONL, Markdown ou bases SQL.
2. **Chunking (Fragmentação):** Divisão dos textos em blocos menores (ex: 500 tokens) com sobreposição (overlap) para manter a continuidade do contexto.
3. **Embedding (Vetorização):** Transformação dos blocos de texto em vetores numéricos de alta dimensão que capturam o significado semântico.
4. **Vector DB (Banco Vetorial):** Armazenamento dos vetores em bancos especializados como ChromaDB, FAISS ou Pinecone para busca por similaridade.
5. **Retrieval & Generation:** A pergunta do usuário é vetorizada, os chunks mais relevantes são buscados e enviados como contexto ao LLM.

💡 Conceitos-Chave

Similaridade de Cosseno: Cálculo matemático usado para medir o quão próximos dois vetores semânticos estão no espaço vetorial.

Grounding (Embasamento): Técnica de forçar o LLM a responder estritamente com base nos trechos recuperados do Vector DB.