

Retrieval-Augmented Generation (RAG Avançado)

CHEAT SHEET #02

Cheat Sheet de Arquitetura, Busca Híbrida & GraphRAG — SECOMP 2026

📌 O que é RAG Avançado?

O RAG Avançado supera o RAG tradicional combinando **Busca Híbrida** (Vetores + Palavras-chave BM25), **Reranking** e **Grafos de Conhecimento (GraphRAG)** para entregar respostas 100% embasadas e livres de alucinações.

⚙️ O Pipeline Moderno de RAG

1. **Ingestão & Semantic Chunking**: Divisão inteligente dos textos por quebra temática/semântica em vez de tamanho fixo.
2. **Dupla Indexação (Hybrid)**: Criação de Embeddings densos (ex: Sentence Transformers) e índices esparsos (BM25).
3. **Recuperação Híbrida & RRF**: Busca simultânea por significado e palavra exata combinadas via *Reciprocal Rank Fusion*.
4. **Reranking com Cross-Encoder**: Reordenação precisa dos top-K contextos com modelos de rerank (Cohere/BGE).
5. **Geração Embasada (Grounded LLM)**: Injeção dos contextos filtrados no prompt delimitado com tags XML.

💡 Conceitos Fundamentais

Reranking: Modelo especializado que avalia a relevância exata do par (Pergunta, Documento) com alta precisão.

GraphRAG: Extração de Entidades e Relações em um Grafo de Conhecimento para responder dúvidas globais sobre o dataset.